01 / MÉMOIRE • CALCUL • ÉNERGIE

Et si la puissance était déjà chez nous ?

Une IA coopérative fondée sur une part des ressources de chacun

Proposition de recherche et d’architecture, avec calculs de capacité, contraintes réseau et expériences numériques.

L’idée directrice
Mettre en commun une fraction réglable des ordinateurs existants, déplacer le calcul vers les données, et réserver la mémoire rapide à ce qui doit réellement répondre immédiatement.

Le scénario étudié utilise **20 % de mémoire comme plafond volontaire**, et non comme prélèvement permanent. La contribution réelle s’adapte à l’activité de chaque machine.

Concept et orientation : Renaud Ben Lakhal
contact@renaud.brussels
7 novembre 2026 • Version 1.4

Recherche et formalisation avec assistance IA. Statut : proposition d’ingénierie et hypothèses de recherche. Calculs analytiques et démonstrateur synthétique exécutés ; aucun réseau de participants, modèle de langage complet ou dispositif biologique testé dans cette étude.

La solution que je retiens

Construire une coopérative de calcul à plusieurs distances.
Les machines proches et autorisées se partagent les parties d'un modèle. Les machines éloignées exécutent des travaux autonomes. Les données rarement utilisées restent sur des supports peu coûteux. Un contrôleur choisit le placement selon la mémoire disponible, le délai et l'énergie.

Cette organisation répond à ton intuition : augmenter l'usage des ressources existantes peut éviter certains achats de matériel. Elle ne transforme cependant pas toute la RAM d'Internet en une carte graphique géante. Le réseau, les calculs et les conversations simultanées imposent leurs propres limites.

Trois niveaux de résultat

Niveau	Ce qui est établi ici
Faisabilité du principe	L'inférence collaborative et le calcul distribué existent dans des systèmes publiés. Ils constituent des points de comparaison, pas notre invention. [1-5]
Solution proposée	Une participation personnelle à quota adaptatif, des groupes formés selon les connexions, une réserve de secours et un placement tenant compte de la chaleur réellement utile.
Recherche plus radicale	Faire demander à la mémoire une décision suffisante, au lieu de lire systématiquement toutes ses valeurs. Un petit test numérique montre des gains et des cas d'échec.

Ce que je ne peux pas conclure : que cette combinaison est sans précédent, qu'elle conserve les capacités d'un modèle de pointe avec une mémoire minuscule, ou qu'un gain mesuré sur un petit calcul s'appliquera à toute une IA.

Lecture : calculs et réseau p. 3-6 ; architecture p. 7-10 ; supports alternatifs p. 11-12 ; hypothèse et expérience p. 13-16 ; prototype p. 17-18 ; sources et reproduction p. 19-22 ; architecture technique détaillée p. 23-34 ; performances simulées p. 35-38 ; installation, vulgarisation et maillage p. 39-44 ; infrastructure et test mondial p. 45-46.

20 % : un plafond utile, pas une quantité garantie

Je retiens **20 % comme réglage de départ à tester**. Ce n’est pas un optimum démontré. La mémoire autorisée doit pouvoir tomber à zéro si l’utilisateur travaille, si la machine manque de mémoire ou si les conditions d’alimentation l’exigent.

Mémoire installée	Plafond à 20 %	Interprétation
8 Go	1,6 Go	Petits modules, cache ou travail léger
16 Go	3,2 Go	Fragment de modèle et mémoire de travail
32 Go	6,4 Go	Modèle compact possible selon son contexte
36 Go	7,2 Go	Plafond théorique pour ton Mac M3 Pro
64 Go	12,8 Go	Contribution plus importante
128 Go	25,6 Go	Hébergement de blocs plus volumineux

Quota effectif = max(0, min(20 % de la mémoire installée, mémoire disponible − réserve de confort, plafond choisi)).

La réserve de confort est un paramètre à calibrer par machine. La mesure doit tenir compte de la pression mémoire et des changements d’activité ; une simple lecture de la mémoire « libre » ne suffit pas. Le quota couvre le processus, ses poids, ses caches et ses buffers, pas seulement le fichier du modèle.

RAM, mémoire unifiée et VRAM

Sur Apple Silicon, CPU et GPU partagent la mémoire unifiée : il ne faut pas les compter deux fois. Sur un PC à GPU dédié, la RAM et la VRAM forment deux budgets différents ; le passage de l’une à l’autre a un coût. La fiche Apple confirme les configurations M3 Pro à 36 Go. [30]

Convention de calcul : Go = 10^9 octets ; To = 10^{12} octets. Gio = 2^{30} octets. Les valeurs affichées par un système peuvent donc différer.

1 000 participants : combien reste-t-il vraiment ?

Voici une population **hypothétique**, choisie pour rendre le calcul vérifiable. Elle ne représente pas une enquête sur le parc informatique des utilisateurs.

Participants	RAM chacun	20 % mis à disposition
100	8 Go	160 Go
400	16 Go	1 280 Go
300	32 Go	1 920 Go
150	64 Go	1 920 Go
50	128 Go	1 280 Go
1 000 au total	32,8 Go en moyenne	6 560 Go = 6,56 To

Avec **40 % de participants disponibles**, une provision de **20 % pour le fonctionnement et les marges**, puis **deux copies des données**, le budget restant est :

6,56 To × 0,40 × 0,80 ÷ 2 = 1,0496 To.
C’est une capacité agrégée de planification, pas un téraoctet contigu de VRAM ni une garantie de service.

Disponibilité simultanée	1 copie	2 copies	3 copies
20 %	1 049,6 Go	524,8 Go	349,9 Go
40 %	2 099,2 Go	1 049,6 Go	699,7 Go
70 %	3 673,6 Go	1 836,8 Go	1 224,5 Go

Un quota fixe de 2 Go donnerait 320 Go dans le même scénario, contre 1 049,6 Go ici. La provision de 20 % est une hypothèse à remplacer par des mesures. Pour une région homogène, la formule devient : mémoire proposée × disponibilité × part exploitable ÷ réplication. Les limitations de connexion et de confiance réduisent encore les groupes réellement utilisables.

La mémoire permet l’accès ; elle ne crée pas l’intelligence

Assembler des ordinateurs donne davantage de capacité et de débit collectif. La qualité dépend toujours du modèle, de son entraînement et de la tâche. Dix petits modèles ne deviennent pas automatiquement un grand modèle équivalent. De nouveaux participants apportent aussi de nouvelles demandes : les ressources par utilisateur ne croissent donc pas sans limite.

Paramètres	Poids à 16 bits	Poids à 4 bits
8 milliards	16 Go	4 Go
14 milliards	28 Go	7 Go
32 milliards	64 Go	16 Go
70 milliards	140 Go	35 Go

Calculs bruts : paramètres × bits / 8. Il faut ajouter échelles de quantification, structures, cache de contexte et buffers. Passer à 4 bits peut dégrader certaines capacités : la compression doit être évaluée.

Exemple de planification : un modèle de 8 milliards

Poids 4 bits : 4 Go ; surcoût supposé de 10 % : 0,4 Go ; cache de contexte : 1 Gio ; buffers supposés : 0,8 Go. Total indicatif : **6,27 Go**. Cela entre arithmétiquement dans 7,2 Go, sans constituer une mesure sur ton Mac. Plusieurs machines à 3,2 Go peuvent accueillir des parties, avec des buffers locaux supplémentaires.

Le coût oublié : chaque conversation

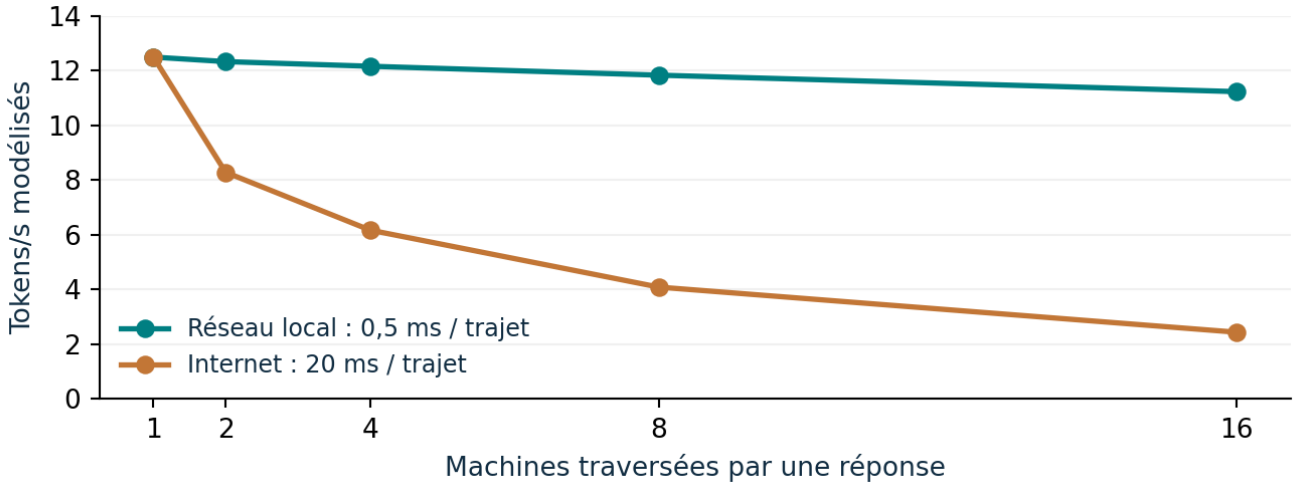
Pour un Transformer hypothétique de 32 couches, 8 têtes KV, dimension 128, cache en 16 bits : **KV = 2 × 32 × 8 × 128 × 2 × tokens**. À 8 192 tokens, cela fait 1 Gio par session. Mille sessions simultanées occupent donc **1 000 Gio, soit environ 1,074 To**, avant les poids et le reste.

Le premier gain d’une grande coopérative sera souvent de servir davantage de travaux en parallèle. Pour une conversation unique, la taille accessible et la vitesse doivent être mesurées séparément.

Le réseau décide de ce qu’on peut partager

La bonne unité de partage est un bloc qui calcule sur place. Déplacer les poids à chaque mot serait trop lent : envoyer 4 Go sur un lien de 100 Mbit/s prend au minimum 320 secondes, hors protocole.

À l’inverse, un état intermédiaire de 4 096 valeurs en 16 bits représente 8 Kio par token. Le trafic peut devenir raisonnable ; la succession des attentes reste pénalisante.



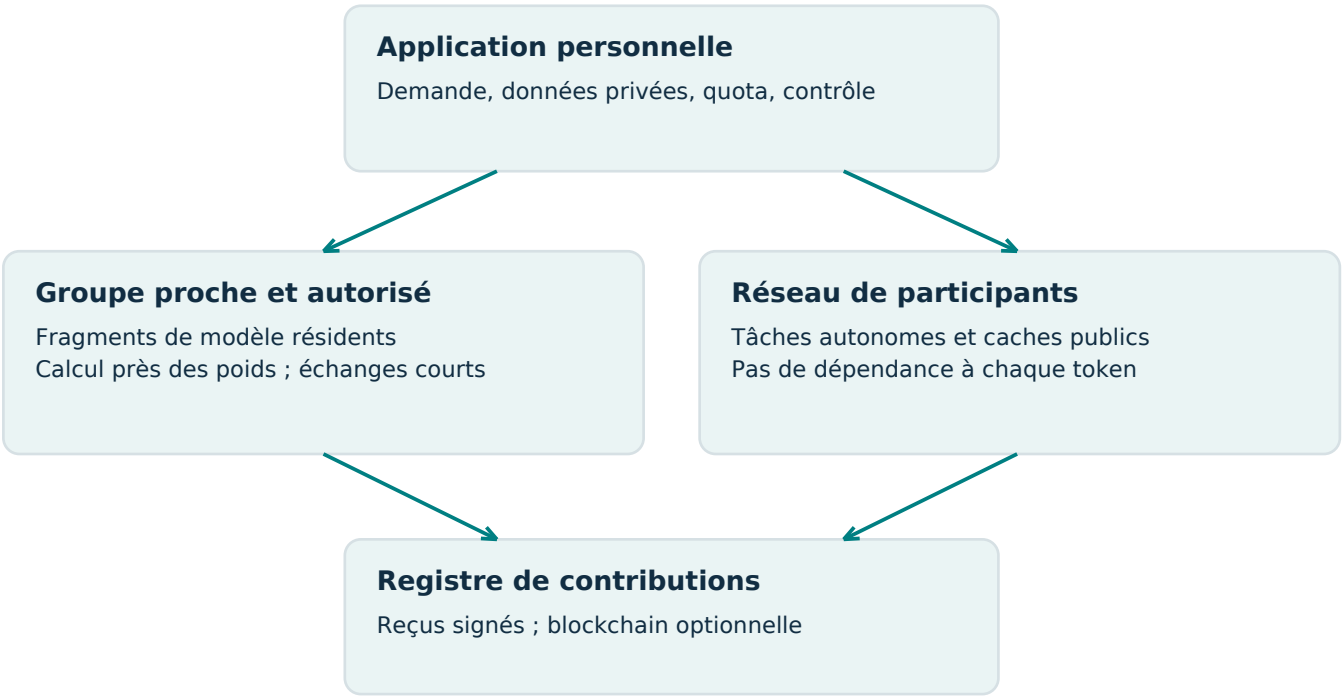
Scénario analytique : même calcul total de 80 ms par token ; réseaux à 1 Gbit/s et 100 Mbit/s ; respectivement 0,5 et 20 ms par trajet. Le dernier nœud renvoie le token au premier. Aucune mesure de matériel.

À 4 machines : environ 12,2 tokens/s sur le réseau local simulé, contre 6,2 sur Internet simulé.
À 8 machines : environ 11,8 contre 4,1 tokens/s.

Pour une génération séquentielle sans spéculation : temps d’un token ≈ somme des temps de calcul + délais de trajet + temps de transfert. Le prochain token dépend du précédent. Plusieurs demandes peuvent être mises en pipeline, mais cela ne supprime pas cette dépendance pour une seule demande.

Le démarrage d’un contexte long est plus lourd : 4 096 tokens × 4 096 valeurs × 2 octets = 32 Mio à une frontière de blocs, soit 2,68 s de transfert brut à 100 Mbit/s. Découpage et recouvrement peuvent aider. Petals et Prima explorent ce type de compromis. [1,3]

L’architecture proposée



Couche	Rôle concret
Personnel	Conserver les données sensibles, choisir les participants autorisés et garder le contrôle de sa contribution.
Groupe rapide	Héberger des blocs contigus du même modèle. Garder les poids et les caches à proximité du processeur qui les utilise.
Coopérative étendue	Distribuer des tâches autonomes : indexation de documents publics, évaluations, traitement de lots, calculs reproductibles.
Registre	Identifier les membres, enregistrer des reçus de travail et attribuer des droits d’usage. Aucun consensus dans la boucle de génération.

Les groupes sont constitués selon les **mesures de connexion et la confiance**, pas seulement selon l’adresse géographique. Deux ordinateurs dans le même bâtiment peuvent être mal connectés ; deux sites reliés par un bon réseau peuvent être compatibles.

Le partage de RAM seule reste possible comme stockage distant, mais il faut alors ramener les données vers un calculateur. La proposition préfère envoyer le travail vers les poids déjà présents : RAM et processeur sont offerts ensemble.

Comment prêter 20 % sans subir son ordinateur

Une offre temporaire, contrôlée par l’utilisateur

Chaque machine annonce : mémoire disponible par type, capacité de calcul mesurée, réseau, plages horaires, état secteur/batterie, limite de puissance et catégories de données autorisées. « 20 % du processeur » devient un plafond de temps CPU ; il ne représente pas une puissance identique sur toutes les machines. Pour le GPU, le rythme et la taille des travaux devront être régulés selon les possibilités du moteur ; un plafond exact de 20 % n’est pas garanti.

État	Comportement proposé
Disponible	Admettre des tâches dans le quota ; conserver les blocs utiles pendant une courte réservation.
Utilisateur actif	Réduire le calcul en priorité ; refuser les nouvelles tâches si la mémoire se tend.
Pression mémoire	Libérer les caches puis les blocs récupérables. Reprendre ailleurs ou redémarrer la demande si son état ne peut être déplacé.
Déconnexion	Détecter l’absence ; utiliser une copie disponible. Sans état de conversation sauvegardé, reconstruire le contexte.
Arrêt demandé	Rendre les ressources à l’utilisateur ; aucune dépendance à une disponibilité permanente.

Le contrôleur doit comparer des options

Pour chaque demande, il estime : faisabilité mémoire, temps de réponse, probabilité d’interruption, énergie et droit d’accès. Il choisit ensuite entre exécution locale, petit groupe, tâche distante autonome ou file d’attente. Ajouter un participant lent peut dégrader une réponse ; le contrôleur doit pouvoir ne pas le sélectionner.

Règle de départ : limiter le nombre de machines sur le chemin d’une seule réponse ; utiliser les participants supplémentaires pour les autres demandes, la préparation et la résilience.

La continuité a un prix : avec 8 nœuds indépendants disponibles chacun à 95 %, la disponibilité simultanée vaut $0{,}95^8 = 66{,}3$ %. Huit paires redondantes donnent théoriquement 98,0 %, si les pannes sont indépendantes. Ce calcul ignore les pannes communes et l’état à restaurer.

09 / ÉTUDE EXPLORATOIRE

Blockchain : où elle aide, où elle devient un coût

La blockchain peut servir de **registre partagé de contributions**. Elle n’est pas le réseau de transport des tenseurs. Gensyn distingue lui aussi communication entre machines, identité et vérification : l’association IA distribuée et blockchain a donc des précédents explicites. [6]

À échanger directement	À consigner éventuellement
Poids de modèles autorisés, états de calcul, résultats et données nécessaires à la tâche.	Identité, version du travail, engagement cryptographique, reçu signé et solde de droits.
Canal chiffré, contrôle des destinataires, reprise de transfert.	Regroupement périodique des reçus ; règlement hors de la boucle interactive.

Commencer avec des reçus signés

Dans un cercle personnel, un journal répliqué de reçus suffit à tester le service. Une blockchain peut être ajoutée si des participants indépendants ont réellement besoin d’un accord commun. Elle apporte alors un coût d’exploitation qu’il faut comparer au bénéfice. Les architectures de passage à l’échelle d’Ethereum déplacent elles-mêmes calcul et état hors chaîne. [7]

Prouver une contribution utile

Récompenser la RAM simplement annoncée serait facile à détourner. Les droits doivent dépendre du travail accepté, du service réellement disponible et de vérifications. Des tests cachés ou des répétitions partielles peuvent détecter certaines erreurs ; ils ne prouvent pas à eux seuls toute une inférence. Les preuves cryptographiques de calcul demandent une étude de coût spécifique.

La confidentialité n’est pas automatique

Le chiffrement du transport protège la liaison, pas du propriétaire de la machine qui exécute le calcul. Les états intermédiaires peuvent révéler de l’information. Pour les dossiers personnels ou parlementaires : groupe de confiance explicite ou calcul local. La documentation Petals conseille un réseau privé pour les données sensibles. [1]

Une preuve de calcul correct ne prouve ni la confidentialité, ni l’absence de copie des données. Aucun document privé, prompt ou état de conversation ne doit être inscrit dans le registre public.

La chaleur est un usage supplémentaire de l’énergie

L’intuition du radiateur informatique est réelle : les radiateurs Q.rad de Qarnot sont documentés, et heata utilise des machines réparties dans des logements pour produire de l’eau chaude. Ces exemples confirment le principe ; cette étude ne confirme pas son attribution précise à Google. [8,9]

La proposition : déplacer les travaux souples

Un travail pouvant attendre peut être envoyé vers une machine disponible qui a un besoin de chaleur. Une réponse interactive doit d’abord respecter son délai et ses contraintes de confidentialité. L’eau chaude peut offrir une demande plus régulière que le chauffage saisonnier, sans supprimer les contraintes d’intégration.

Exemple hypothétique : un ordinateur absorbe 300 W pendant 2 h, soit 0,60 kWh. Avec 80 % de chaleur effectivement récupérée, la chaleur utile est de 0,48 kWh.

Chauffage remplacé	Électricité évitée	Solde du calcul après ce crédit
Résistance électrique	0,48 kWh	0,12 kWh
Pompe à chaleur, COP 3	0,16 kWh	0,44 kWh
Aucun besoin de chaleur	0 kWh	0,60 kWh

Ces soldes ne comparent pas encore la solution à un centre de données. Il faut aussi compter le calcul qui aurait été effectué ailleurs, le réseau, la veille des machines, les reprises et les pertes. Le COP est ici fixé à 3 pour illustrer le calcul, pas mesuré.

Un critère de décision mesurable

Comparer l’énergie totale des travaux terminés correctement, en comptant séparément la chaleur utile. Un ordinateur allumé toute la nuit pour garder un cache rarement consulté peut coûter plus que ce qu’il fait économiser. Le contrôleur doit pouvoir vider ce cache et laisser dormir la machine.

Valoriser la chaleur ne justifie pas un calcul inutile. Le besoin de calcul et le besoin thermique doivent tous deux exister.

ADN, cellules, « chair » : ce qui est réellement possible

La matière biologique peut porter des données. Cela ne signifie pas qu'un morceau de viande fonctionne comme une barrette de RAM. Il faut un encodage, un mécanisme d'adressage, un lecteur et une correction des erreurs.

Démonstration publiée	Ce qu'elle établit
ADN synthétique, 2018	Plus de 200 Mo dans 35 fichiers, récupérés individuellement. Stockage moléculaire, pas mémoire de travail d'un GPU. [10]
Cellules vivantes, 2021	Encodage électrique de données dans des bactéries ; démonstration allant jusqu'à 72 bits. [11]
Marques épigénétiques, 2024	Écriture d'environ 275 000 bits par modification de molécules préparées, sans synthèse de novo à chaque message. [12]
Accès Cas9, 2025	Sélection de fichiers et recherche par similarité dans une base moléculaire ; accès expérimental accéléré. Ce n'est pas un bus mémoire électronique. [13]
Microsphères vivantes, 2026	Petites images encodées dans des bactéries, récupération et régénération ; les grandes performances annoncées comme bornes de modèle restent théoriques. [14]

La question intéressante n'est pas seulement « où stocker ? »

Une piste de recherche serait de **faire effectuer une sélection grossière par la matière**, puis ne lire électroniquement que les candidats utiles. Cela vise des archives massives et des délais souples. La recherche moléculaire et le calcul dans l'ADN ont déjà des démonstrations : la contribution éventuelle serait un système complet moins coûteux, pas la découverte du principe. [13,31]

Pour cette coopérative, l'ADN resterait une branche de recherche sur l'archivage. Il n'existe dans les sources étudiées aucune démonstration justifiant de le placer dans la boucle rapide de génération d'un grand modèle de langage.

Changer de support : quels problèmes cela résout-il ?

Piste	Intérêt	Limite et place proposée
RAM déjà présente	Évite un achat si la machine et le réseau conviennent.	Volatile, consommation de veille, disponibilité. Première piste pratique.
SSD et archives réparties	Stocker les blocs rarement utilisés à faible pression RAM.	Lecture plus lente ; conserver les blocs utiles près du calcul.
Verre optique	Conservation durable : Project Silica explore notamment le verre borosilicaté. [15]	Archivage ; pas remplacement direct de la mémoire de travail.
Mémoire calculante électronique	Effectuer certaines opérations dans les cellules de mémoire ; IBM a démontré une puce analogique multicœur. [16]	Précision, conversion, dérive et intégration ; programme matériel spécialisé.
Photonique avec mémoire	Rapprocher signaux, calcul et mémorisation ; démonstrations neuromorphiques. [17]	Résultats sur tâches précises ; ne pas extrapoler à tout un LLM.
Neurones et organoïdes	Apprentissage et dynamique biologique expérimentale. [18]	Pas une RAM numérique interchangeable ; maintien biologique et interfaces.
ADN	Densité et conservation, sélection moléculaire possible.	Écriture, lecture et traitement chimique ; usage différé.

Aucune matière ne gagne automatiquement sur tous les axes : capacité, latence, débit, énergie, endurance, coût et fiabilité. La démarche consiste à confier à chaque support une fonction pour laquelle il a un avantage mesurable.

Le changement de perspective : concevoir une mémoire selon le délai et le résultat attendus, au lieu de chercher un unique support censé tout remplacer.

La piste de recherche qui dépasse le simple partage

Remplacer « donne-moi tous les nombres » par « donne-moi le résultat nécessaire, avec une limite d’erreur ».
La mémoire devient un service qui répond à une opération, à une échéance et à un niveau de précision.

Exemple : pour choisir un expert ou un document, le système n’a pas toujours besoin de connaître tous les scores avec précision. Il a besoin de savoir lequel l’emporte. Une représentation compacte peut éliminer des candidats ; seuls les cas ambigus demandent une lecture plus détaillée.

Une architecture à deux temps

Temps 1 : sur la machine locale, lire une représentation petite, des métadonnées et une borne d’erreur. **Temps 2 :** si la décision reste ambiguë, demander un complément à une mémoire proche ou à un participant autorisé. Le résultat doit être vérifié selon un contrat précis : meilleure classe, top-k ou erreur maximale sur un vecteur.

Ce qui constituerait la contribution à rechercher

Faire choisir **ensemble** au contrôleur : le résultat à calculer, la précision à lire, le participant à solliciter et le délai acceptable, sous un quota personnel variable. Les données peu déterminantes restent éloignées ; les détails qui changent réellement la décision sont rapprochés.

La question scientifique est : peut-on économiser davantage d’octets et d’énergie que le coût des bornes, de la coordination et des reprises, à qualité contrôlée ? Elle se teste face à la quantification fixe, au cache classique et au calcul intégral.

L’originalité reste à établir

La précision progressive, la recherche de produits scalaires et certaines transformations préservant les sorties ont déjà des antécédents. [27-29] Je ne revendique pas leur invention. La combinaison proposée est une hypothèse de système ; aucune recherche bibliographique ne permet de garantir que personne ne l’a étudiée.

Un test exécuté : lire jusqu’à pouvoir décider

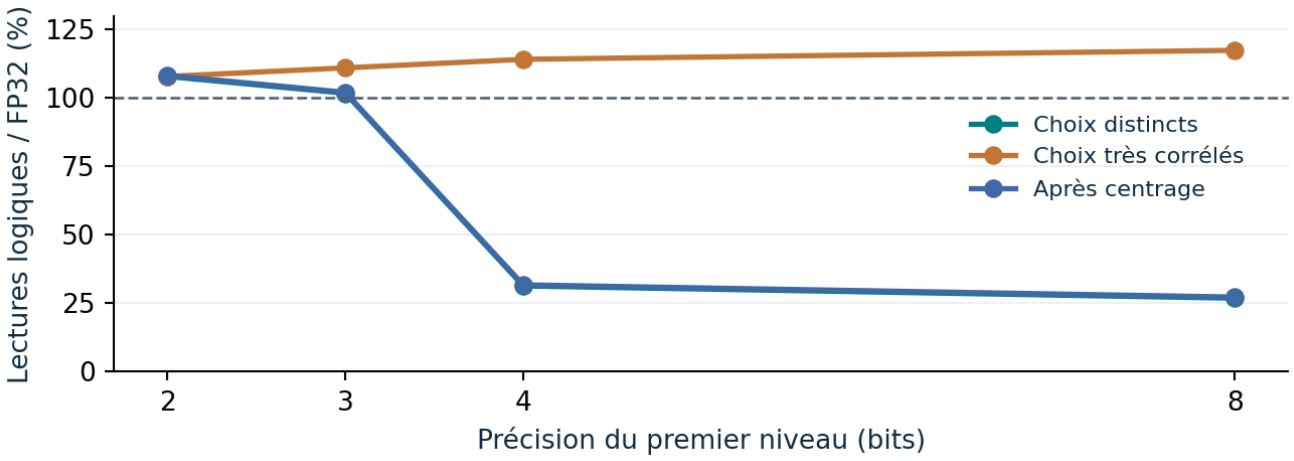
J’ai construit un démonstrateur de sélection du plus grand score parmi 512 candidats de dimension 256. Il simule une représentation compacte et la récupération de lignes précises. Ce n’est pas l’exécution d’un modèle de langage.

Le mécanisme mathématique

Pour un candidat i, le score exact est $w_i \cdot x$. On utilise une approximation q_i de $w_i - c$, où c est un vecteur commun optionnel. Soustraire $c \cdot x$ à tous les scores préserve leur ordre. On calcule :

score approximatif : $s_i = q_i \cdot x$
borne : $e_i = ||w_i - c - q_i||_2 \times ||x||_2$
score exact centré compris entre $s_i - e_i$ et $s_i + e_i$

On lit exactement un candidat initial. On affine ensuite les candidats dont la borne haute peut encore dépasser le meilleur score exact connu. Dès que toutes les bornes restantes sont inférieures, le gagnant est déterminé. En cas d’ambiguïté, la méthode peut finir par tout lire.



Les « lectures » sont des volumes logiques modélisés, incluant la première représentation et ses métadonnées. Les transferts matériels, caches CPU, latences et joules ne sont pas mesurés. Référence : poids FP32, calculs numériques FP64.

Résultats : un gain conditionnel, et un échec instructif

Cas synthétique	Bits	Lectures / référence	Décisions différentes
Candidats indépendants	2	107,8 %	0 / 800
Candidats indépendants	4	31,3 %	0 / 800
Candidats indépendants	8	26,8 %	0 / 800
Candidats très corrélés	4	114,1 %	0 / 800
Même cas, après centrage	4	31,7 %	0 / 800
Même cas, après centrage	8	27,2 %	0 / 800
Candidat très favorisé	3	11,1 %	0 / 800

12 800 évaluations ont été exécutées au total : quatre configurations de données, quatre précisions, quatre graines et 200 requêtes par graine. Les mêmes requêtes sont réutilisées entre précisions ; ce ne sont pas 12 800 observations indépendantes. Aucun désaccord avec la sélection de référence n’a été observé.

Ce que ce test apprend réellement

Une approximation trop grossière peut faire lire **plus** de données que la méthode directe. Les candidats très corrélés font échouer la première version. Retirer une composante commune corrige ce cas synthétique ; cette transformation a elle-même des précédents publiés. [27] La variante 8 bits est ici meilleure que la variante 4 bits sur les candidats indépendants.

Ce qu’il ne démontre pas

Ces résultats ne prouvent ni une accélération, ni une baisse de consommation, ni une réduction équivalente de la RAM d’un LLM. Le stockage total peut même augmenter, puisque représentation compacte et poids de référence coexistent. Le gain possible porte sur les données rapides consultées.

La borne découle de Cauchy-Schwarz en arithmétique réelle. Le code utilise une petite marge numérique, sans arithmétique d’intervalles formellement certifiée. Le test vérifie empiriquement le résultat ; il ne constitue pas une certification informatique complète.

Écarter les fausses percées

Intuition	Antécédents ou obstacle	Décision de recherche
Tous les PC deviennent une IA	Petals, exo, Prima, Hivemind. [1-4]	Étudier les quotas faibles, la qualité de service et les coûts réels.
Une blockchain règle la coopération	Gensyn sépare déjà communication, identité et vérification. [6]	Tester si un registre supplémentaire apporte assez de valeur.
Mettre la connaissance hors du modèle	RAG, Engram et TF-Engram. [20,21,25]	Comparer à ces références ; ne pas rebaptiser le principe.
Ne conserver qu'un petit état	Mamba et mémoires récurrentes. [22]	Mesurer les pertes sur le rappel précis et les contextes longs.
Tout passer à très peu de bits	BitNet et autres méthodes spécialisées. [19]	Vérifier le modèle et le moteur ; pas de conversion magique universelle.
Transformer un support biologique en RAM	Lecture, écriture et interfaces physiques.	Séparer stockage différé et mémoire interactive.

Le véritable critère de progrès

Une avancée serait de fournir le **même service utile** avec moins de mémoire rapide, moins d'énergie totale et un délai acceptable, en intégrant le réseau et les erreurs. Une grande capacité agrégée ou une démonstration spectaculaire ne suffisent pas.

Sur le chemin radical, il faut tester la sélection à précision adaptative contre une version fixe 8 bits, une lecture directe et une recherche approchée existante. Sur le chemin coopératif, comparer le même modèle et les mêmes tâches sur une machine, puis 2, 4 et 8 participants.

Le premier produit testable est la coopérative à quota adaptatif. La contribution scientifique éventuelle serait une méthode qui réduit le coût des échanges nécessaires, démontrée au-delà des cas synthétiques.

Un prototype qui tranche les questions importantes

Étape	Travail	Critère de passage proposé
1. Mesurer	Deux à quatre machines autorisées ; mémoire, réseau, débit du modèle, consommation à la prise.	Choisir un modèle et figer une référence de qualité.
2. Comparer les quotas	10 %, 20 %, 30 %, plus un plafond fixe ; enregistrer aussi l’activité normale des machines.	Retenir le meilleur compromis mesuré, pas imposer 20 %.
3. Répartir	Un modèle fractionné dans un groupe proche ; tâches autonomes entre groupes.	Capacité accrue avec délai acceptable ; aucune saturation mémoire.
4. Perturber	Départs de nœuds, liens ralentis, reprise d’activité, demandes simultanées.	Repli explicite ; aucune réponse annoncée complète après un échec.
5. Élargir	20 participants, puis 100 ; mesurer disponibilité et coût de vérification.	Confirmer les gains avant d’extrapoler à 1 000.

Un banc d’essai adapté à tes usages

Préparer 240 tâches de test, distinctes de la mise au point : 60 extractions documentaires, 60 résumés ou traductions FR/NL/EN, 60 calculs ou transformations vérifiables, 60 cas difficiles avec informations absentes ou contradictoires. Pour les premiers essais partagés : données publiques ou synthétiques.

Mesurer la qualité par tâche, le temps avant la première réponse, le débit, le délai au 95e percentile, la mémoire maximale, les octets réseau, les interruptions et les joules par travail terminé. Ajouter 1, 4 puis 16 demandes concurrentes.

Seuils exploratoires à fixer avant le test : perte de qualité maximale de 2 points ; économie mémoire ou énergétique de 30 % ; délai au 95e percentile inférieur à 1,5 fois la référence comparable. Ce sont des objectifs, pas des performances obtenues. Les intervalles d’incertitude peuvent imposer davantage de tâches.

Jusqu’où cette solution peut-elle aller ?

Ce qu’elle peut changer

Une coopérative peut rendre accessibles des modèles qui ne tiennent pas sur une seule petite machine, mutualiser les téléchargements, absorber des lots et mieux utiliser du matériel existant. L’utilisateur apporte une fraction réversible de sa machine ; il reçoit un service mesuré, pas une promesse de puissance infinie.

Ce qu’elle ne règle pas à elle seule

L’entraînement initial ajoute gradients, états d’optimisation, activations et synchronisation. L’inférence distribuée ne résout donc pas automatiquement le coût d’entraînement. DiLoCo explore une réduction des communications entre groupes ; QLoRA réduit certains besoins d’adaptation d’un modèle déjà entraîné. [5,26]

Pour le contexte et les accès mémoire, FlashAttention et PagedAttention constituent aussi des références utiles. Ils traitent respectivement certains transferts de l’attention et la gestion des caches ; ils n’effacent pas le stockage des poids. [23,24]

La direction d’invention à poursuivre

Le système devrait apprendre à choisir **ce qui doit être précis, proche et immédiat**, et ce qui peut rester approximatif, distant ou différé. Cette décision commune sur le calcul, la mémoire et le placement est le cœur du programme proposé. Les supports biologiques et optiques pourraient y trouver une place si leur bilan complet devient favorable.

Conclusion de l’étude : l’idée de partager une part personnelle de mémoire et de calcul est réalisable dans son principe. La version la plus crédible repose sur de petits groupes rapides, des tâches autonomes à distance et des contributions adaptatives. Une percée scientifique universelle n’a pas été démontrée ici.

Travail réalisé : recherche de sources primaires, architecture, calculs de capacité et de réseau, démonstrateur numérique et analyse des échecs. Travail restant pour valider : exécuter le même modèle sur des machines réelles, instrumenter énergie et mémoire, puis faire reproduire les résultats. Aucun service distribué n’a été déployé.

Sources et antécédents

Sources primaires, dépôts officiels et documentation des équipes. Consultés le 7 novembre 2026. Les résultats des auteurs ne sont pas présentés comme reproduits. Les calculs et le démonstrateur de cette étude sont identifiés séparément.

[1] Borzunov et al. - Distributed Inference and Fine-tuning of Large Language Models Over the Internet. NeurIPS, 2023.
arXiv 2312.08361
Petals : inférence collaborative ; documentation et confidentialité : https://github.com/bigscience-workshop/petals

[2] exo labs - exo, dépôt officiel. État consulté le 7 novembre 2026.
github.com/exo-explore/exo
Répartition selon la topologie et les ressources. Les performances du dépôt ne sont pas reproduites ici.

[3] Li et al. - Prima.cpp: Fast 30-70B LLM Inference on Heterogeneous and Low-Resource Home Clusters. Version 3, juillet 2026.
arXiv 2504.08791
Prépublication ; systèmes hétérogènes domestiques.

[4] Learning at home - Hivemind, dépôt officiel.
github.com/learning-at-home/hivemind
Briques pour apprentissage décentralisé et tolérance aux interruptions.

[5] Douillard et al. - DiLoCo: Distributed Low-Communication Training of Language Models. 2023 ; version 3, 2024.
arXiv 2311.08105
Apprentissage distribué à communication réduite.

[6] Gensyn - Infrastructure, documentation officielle.
gensyn.ai/infrastructure
Communication pair à pair, identité sur chaîne et vérification : description du projet, pas validation indépendante.

[7] Ethereum - Scaling et Zero-knowledge rollups, documentation officielle.
ethereum.org - ZK-rollups
Séparation entre exécution hors chaîne et vérification/règlement.

[8] Éduscol, revue Technologie - Rubriques innovation, Q.rad / Qarnot.
Éduscol - archive Technologie, Q.rad
Document technique institutionnel sur le principe du radiateur numérique ; ne décrit pas une offre actuelle.

[9] heata - Sustainable cloud compute, présentation officielle.
heata.co/compute
Calcul distribué dans les logements et valorisation de chaleur. Les gains commerciaux annoncés ne sont pas repris.

[10] Organick et al. - Random access in large-scale DNA data storage. Nature Biotechnology, 2018.
doi:10.1038/nbt.4079
Stockage et récupération individuelle de fichiers dans l’ADN.

Sources et antécédents

[11] Yim et al. - Robust direct digital-to-biological data storage in living cells. Nature Chemical Biology, 2021.
PubMed 33432236
Démonstration numérique vers biologique dans des bactéries.

[12] Zhang et al. - Parallel molecular data storage by printing epigenetic bits on DNA. Nature, 2024.
doi:10.1038/s41586-024-08040-5
Écriture par modifications épigénétiques sur supports préparés.

[13] Random access and semantic search in DNA data storage enabled by Cas9 and machine-guided design. Nature Communications, 2025.
doi:10.1038/s41467-025-61264-5
Adressage de fichiers et recherche moléculaire par similarité.

[14] Luo et al. - Thermo-Responsive Living Microspheroids Enable a Regenerative Living Disk-Drive System for DNA Data Storage. Advanced Materials, 2026.
PubMed 42335403 ; doi:10.1002/adma.73806
Démonstration biologique de petite taille ; distinguer résultats expérimentaux et bornes de modèle.

[15] Microsoft Research - Project Silica's advances in glass storage technology. 18 février 2026.
Microsoft Research - Project Silica, 2026
Présentation par l'équipe de la publication Nature, doi:10.1038/s41586-025-10042-w.

[16] IBM Research - A 64-core mixed-signal in-memory compute chip based on phase-change memory for deep neural network inference. Nature Electronics, 2023.
IBM Research - puce analogique 64 cœurs
Démonstration de calcul dans la mémoire, sur les réseaux testés par les auteurs.

[17] Lam et al. - Neuromorphic photonic computing with an electro-optic analog memory. Nature Communications, 2026.
doi:10.1038/s41467-026-69084-x
Mémoire analogique électronique associée à la photonique ; démonstration sur MNIST.

[18] Jordan et al. - Open and remotely accessible Neuroplatform for research in wetware computing. Frontiers in Artificial Intelligence, 2024.
doi:10.3389/frai.2024.1376042
Plateforme de recherche sur les réseaux neuronaux biologiques.

[19] Microsoft - BitNet, dépôt officiel et rapports associés.
github.com/microsoft/BitNet
Modèles ternaires et moteurs spécifiques ; pas de garantie de conversion d'un modèle quelconque.

[20] Cheng et al. - Conditional Memory via Scalable Lookup: A New Axis of Sparsity for Large Language Models. 2026, version 2.
arXiv 2601.07372
Engram : mémoire conditionnelle intégrée au modèle.

Sources et antécédents

[21] Ma et al. - TF-Engram: A Train-Free Engram with SSD-Backed Memory for Large Language Models. Juillet 2026.
arXiv 2607.07388
Prépublication ; tables de mémoire sur plusieurs niveaux de stockage.

[22] Gu et Dao - Mamba: Linear-Time Sequence Modeling with Selective State Spaces. 2023 ; version 2, 2024.
arXiv 2312.00752
Architecture récurrente à états sélectifs.

[23] Kwon et al. - Efficient Memory Management for Large Language Model Serving with PagedAttention. SOSP, 2023.
arXiv 2309.06180
Gestion des caches de clés et valeurs dans vLLM.

[24] Dao et al. - FlashAttention: Fast and Memory-Efficient Exact Attention with IO-Awareness. NeurIPS, 2022.
arXiv 2205.14135
Réduction de certains échanges mémoire de l’attention exacte.

[25] Lewis et al. - Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. 2020.
arXiv 2005.11401
Association entre un modèle et une mémoire documentaire externe.

[26] Dettmers et al. - QLoRA: Efficient Finetuning of Quantized LLMs. 2023.
arXiv 2305.14314
Adaptation avec poids de base quantifiés et adaptateurs entraînables.

[27] Kadav et al. - Softmax Reparameterization for Output-Head Quantization. Septembre 2026, version 2.
arXiv 2609.31291
Prépublication ; antécédent explicite du centrage préservant les sorties avant quantification.

[28] Chen et al. - Progressive Mixed-Precision Decoding for Efficient LLM Inference. 2024 ; version 2, 2025.
arXiv 2410.13461
Précision modulée selon les phases de l’inférence.

[29] Mussmann et Ermon - Learning and Inference via Maximum Inner Product Search. ICML, 2016.
PMLR 48, p. 2587-2596
Lien entre recherche de produits scalaires et inférence probabiliste.

[30] Apple - MacBook Pro 14 pouces, M3 Pro ou M3 Max, novembre 2023 : caractéristiques techniques.
support.apple.com/117736
Mémoire unifiée et configurations matérielles ; aucune mesure du Mac de l’utilisateur.

[31] Parallel molecular computation on digital data stored in DNA. PNAS, 2023.
doi:10.1073/pnas.2217330120
Calcul moléculaire sur des registres expérimentaux ; ne démontre pas un LLM moléculaire.

Reproduire et contredire les calculs

Ce PDF contient huit fichiers joints : quatre scripts Python et leurs résultats JSON. Ils sont accessibles depuis le panneau des pièces jointes d’un lecteur PDF compatible. Aucun accès à un service d’IA ni clé API n’est nécessaire.

Fichiers joints	Contenu
experiment.py / results.json	Sélection adaptative, quatre jeux/configurations, quatre précisions, résultats complets. Nécessite NumPy.
network_model.py / network_results.json	Modèle analytique de latence, volumes transférés, disponibilité et chaleur. Python standard.
pool_model.py / pool_results.json	Population hypothétique, quotas à 20 %, disponibilité et réplication. Python standard.
service_simulation.py / service_results.json	File de demandes, variabilité et incidents. Huit scénarios, 160 000 demandes simulées. Python standard.

Paramètres du démonstrateur

Graines : 17, 29, 43, 71. Matrices : 512 × 256. Poids issus de tirages gaussiens, stockés comme valeurs FP32 puis évalués en FP64. 200 requêtes par graine. Précisions : 2, 3, 4, 8 bits, quantification symétrique par ligne. Environnement d’exécution : Python 3.12.14, NumPy 2.3.5.

Cas corrélé : vecteur commun + 0,025 fois le bruit indépendant. Variante centrée : retrait de la moyenne des lignes avant approximation. Cas favorisé : requête alignée avec un candidat. Les distributions ont été choisies pour explorer des régimes, pas pour représenter un LLM réel.

Comptabilité des lectures

Référence par requête : 512 × 256 × 4 octets. Variante : représentation à b bits + 16 octets de métadonnées par ligne + 8 octets par dimension pour le centre si activé + lignes FP32 relues. Le code émule ces formats en tableaux numériques ; les octets indiqués ne sont pas la RAM réellement allouée par Python.

La prochaine expérience qui peut invalider l’idée

Remplacer les données synthétiques par les activations et poids d’une vraie tête de sortie. Mesurer l’égalité des choix, la distribution complète si un échantillonnage est utilisé, puis les lectures physiques, la latence et l’énergie. Si les bornes restent trop larges ou si la coordination coûte plus que les lectures évitées, abandonner cette variante.

Une égalité du meilleur score ne garantit pas l’égalité de toute la distribution softmax, ni d’une génération échantillonnée. Un gain sur une tête de sortie ne vaut pas un gain identique sur l’ensemble du modèle.

Architecture technique : les composants à construire

Le périmètre de départ est une coopérative privée, sur invitation. Chaque demande possède un coordinateur sur la machine de son initiateur. Le réseau ne dépend pas d'un coordinateur unique pour toutes les demandes. Les composants ci-dessous sont proposés ; ils ne sont pas déployés.

Composant	Responsabilité	État conservé
Application personnelle	Chat, choix du modèle, autorisations, jauges, arrêt du partage.	Préférences et conversations locales.
Contrôleur de ressources	Calcul des quotas, activité utilisateur, pression mémoire et alimentation.	Mesures récentes ; allocations en cours.
Coordinateur de demande	Choix des nœuds, réservation, version du plan, suivi et reprise.	Plan de session ; journal des tokens validés.
Exécuteur de blocs	Charger un fragment, traiter des tenseurs, gérer le cache de contexte.	Poids, buffers et KV des sessions admises.
Catalogue distribué	Localiser des blocs et leurs copies ; vérifier versions et empreintes.	Métadonnées publiques de modèles autorisés.
Transport	Authentification mutuelle, flux, annulation, reprise de téléchargement.	Connexions, séquences et compteurs.
Comptabilité	Reçus de service et droits ; vérifications et contestations.	Reçus signés, pas les conversations.

Séparation structurante : le plan de contrôle décide et réserve ; le plan de données transporte les calculs ; le registre tient les comptes après coup. Un retard du registre ne bloque pas un token en cours.

L'application peut utiliser un petit modèle local de secours. Ce modèle doit être identifié à l'utilisateur lorsqu'il remplace le modèle demandé ; la continuité ne doit pas masquer un changement de capacité.

Budget mémoire et cycle de vie d’une machine

Une machine passe par les états : **arrêtée, disponible, réservée, occupée, réduction de charge, indisponible**. Le contrôleur de ressources reste prioritaire sur les engagements de service : l’utilisateur conserve toujours la possibilité d’arrêter sa contribution.

Un budget complet, par type de mémoire

> Budget admis ≥ poids résidents + KV réservé + buffers maximaux
> + moteur d’exécution + transport + marge mesurée.
> Aucun nouveau travail ne commence si cette inégalité n’est pas respectée.

Les buffers maximaux sont estimés pendant un échauffement mesuré du modèle avec la taille de contexte autorisée. Le budget est réservé avant le calcul. Le nombre de sessions ne croît que si les quotas et le débit le permettent.

Situation	Décision
Quota augmente	Accepter progressivement de nouvelles réservations ; charger des blocs utiles.
Quota baisse	Refuser les nouvelles sessions ; évincer les caches non utilisés ; terminer ou interrompre selon l’urgence.
Machine sur batterie	Partage arrêté par défaut dans le prototype ; activation volontaire possible.
Utilisateur reprend son travail	Ralentir ou suspendre les tâches différables ; libérer la mémoire selon la pression.
Température ou puissance limite	Réduire le rythme ; le besoin de chaleur ne permet pas de dépasser les limites du matériel.

Sous Linux, les contrôleurs cgroup v2 permettent de limiter le temps CPU et la mémoire des processus. Ils ne constituent pas une limite universelle de VRAM. [32] Sur macOS, le prototype doit combiner admission, mesure du moteur, supervision et arrêt du processus si nécessaire ; il ne faut pas promettre une limite système dure de 20 % sur toute allocation GPU.

Le contrôleur et l’interface consomment eux-mêmes des ressources : celles-ci appartiennent au budget, même lorsque le modèle est déchargé.

Découverte, identité et communications

Entrer dans le cercle

L’utilisateur crée une identité de machine. Un code d’invitation permet l’appairage et la validation de sa clé. Une autorisation précise les groupes, modèles et catégories de tâches accessibles. La révocation interdit de nouvelles sessions et ferme les sessions concernées selon la politique choisie.

Trouver les participants

Dans le réseau local, la découverte ne vaut pas autorisation : une machine détectée doit toujours être appairée. À distance, un annuaire de rendez-vous limité au groupe met les pairs en relation. Plusieurs annuaires peuvent répliquer les annonces signées à durée courte. Ils ne reçoivent pas les conversations.

Transport proposé pour le prototype

gRPC avec authentification TLS mutuelle fournit les échanges de contrôle et les flux de tenseurs. Délais, annulation et régulation du débit sont explicites. gRPC documente les flux bidirectionnels et le contrôle de flux. [33] Ce choix vise d’abord une implémentation lisible ; des transports spécialisés pourront ensuite remplacer le chemin local rapide.

Les réseaux empêchant une connexion directe utilisent une passerelle autorisée. Elle relaie un canal chiffré de bout en bout entre les pairs ; son coût et sa latence sont comptés. Si le relais rend le délai inacceptable, le groupe n’est pas retenu pour la génération interactive.

Canal	Contenu	Règle
Contrôle	Offres, réservations, plans, annulations.	Petits messages prioritaires ; expirations obligatoires.
Calcul	Activations, tokens, sorties d’opérations.	Flux bornés, séquence et version de plan.
Blocs	Téléchargement de poids et vérification.	Transfert en arrière-plan ; reprise par morceaux.
Comptes	Reçus et résultats de vérification.	Asynchrone ; aucune attente par token.

Placer le modèle sans faire exploser les échanges

Le premier prototype partage des **groupes de couches contiguës**. Il évite de découper chaque multiplication entre des machines Internet : ce type de parallélisme demanderait des échanges beaucoup plus fréquents.

Manifeste d’un modèle

Chaque modèle décrit son identifiant, sa version, son tokenizer, ses règles de positionnement, le format de ses poids, ses blocs, leur empreinte et leurs dimensions. Le moteur doit confirmer sa compatibilité. Les métadonnées nécessaires au chargement appartiennent à chaque bloc.

Admission et placement

1. Filtrer les machines par autorisation, compatibilité et disponibilité.
2. Mesurer leur débit sur les blocs représentatifs et leurs liaisons.
3. Écarter tout placement qui dépasse un quota ou un contexte autorisé.
4. Minimiser le délai estimé, puis les transferts et l’énergie.
5. Réserver tous les blocs avant de commencer ; abandonner le plan incomplet.

Objectif du premier moteur de placement :
un petit nombre de frontières réseau, des poids déjà chargés et des réservations compatibles avec le contexte demandé. La charge est répartie selon le temps mesuré, pas selon le seul nombre de couches.

L’admission emploie une réservation en deux phases : proposition courte, puis confirmation du plan complet. En cas de refus ou d’expiration d’un nœud, les autres réservations sont libérées. Chaque tentative a un identifiant distinct.

Ce qui change pour un modèle à experts

Les experts actifs ne représentent pas tous les poids à conserver. Le routage peut aussi changer à chaque token. Il faudra mesurer la réutilisation des experts et le coût des manques avant d’activer ce mode. Un cache d’experts distant ne doit pas être supposé aussi rapide qu’un expert résident.

Le changement de participants pendant une session implique une nouvelle version de plan et une reconstruction ou migration contrôlée du cache. Les anciennes réponses sont rejetées.

Du message de l’utilisateur au token affiché

Étape	Échange ou action	Contrôle
1	L’application reçoit le message.	Choix de confidentialité et du groupe autorisé.
2	Le coordinateur estime le contexte et les buffers.	Limite de tokens, mémoire et délai.
3	Il réserve les blocs, puis confirme le plan.	Versions du modèle, du tokenizer et des nœuds.
4	Le contexte est traité par morceaux.	Ordre des positions ; aucun dépassement KV.
5	Les blocs transmettent leurs activations au suivant.	Session, position du token, forme et type du tenseur.
6	Le dernier bloc applique la règle de sélection prévue.	Paramètres et état aléatoire fixés pour la session.
7	Le token accepté revient au coordinateur.	Déduplication et validation de la séquence.
8	L’application affiche le token et poursuit ou clôture.	Limite de sortie ; annulation possible à tout instant.

Le modèle réseau de la page 6 suppose que la sélection s’effectue sur le dernier nœud et qu’un identifiant de token revient au coordinateur. Si l’on exige le retour de tous les scores du vocabulaire, le trafic augmente ; il faut refaire le calcul de réseau.

Reprise et reproductibilité

Le coordinateur conserve localement les tokens déjà validés, les paramètres de sélection et l’état nécessaire à la reprise. Rejouer les tokens connus reconstruit le contexte sans les tirer à nouveau. Une identité numérique parfaite entre processeurs différents n’est pas présumée : elle se teste, ou la garantie est limitée à des moteurs compatibles.

Le contrôle du transport ne vérifie pas à lui seul la justesse des calculs. Dans la version privée, la confiance repose sur les participants autorisés et des tests de conformité. L’ouverture à des inconnus nécessite une vérification supplémentaire chiffrée en coût.

Mémoire des conversations et données persistantes

Donnée	Emplacement proposé	Durée / protection
Poids publics autorisés	Caches des participants.	Persistants sur disque si quota accordé ; vérification d’intégrité.
Prompt et conversation	Machine de l’utilisateur ; nœuds de calcul autorisés lorsque nécessaire.	Historique local réglable ; traitement distant limité à la session.
Cache KV	Nœud responsable des couches correspondantes.	Mémoire volatile ; libération à la clôture ou à l’expiration.
Plan et tokens validés	Coordinateur personnel.	Journal de reprise local ; chiffrement si persistant.
Reçus de service	Participants concernés et registre du groupe.	Métadonnées minimales, sans contenu de conversation.
Mesures de performance	Localement, puis agrégats autorisés.	Rétention courte ; pas de journal des tenseurs par défaut.

La réplication des poids ne réplique pas une session

Une copie des poids accélère un remplacement de machine. Elle ne possède pas automatiquement le cache KV de la conversation. Le prototype privilégie la reconstruction depuis le journal local ; une copie du KV est une optimisation ultérieure, avec un coût réseau, mémoire et confidentialité explicite.

Cloisonner les utilisateurs

Chaque session a un propriétaire, un espace KV et un compteur de budget. Un cache partagé entre utilisateurs n’est permis que pour un préfixe public et explicitement autorisé. Un simple hash de prompt ne rend pas automatiquement ce prompt anonyme.

Libérer une allocation ne permet pas de promettre un effacement physique vérifiable chez un participant. Le niveau de confiance du groupe reste déterminant ; un chiffrement de disque ou du réseau ne protège pas d’un hôte autorisé qui copie les données pendant le calcul.

Pannes, reprises et refus de service

Événement	Réaction immédiate	Reprise
Nœud ne répond plus	Interrompre le flux à sa limite de temps ; invalider la tentative.	Réserver un remplaçant et reconstruire son contexte.
Quota retiré	Réduire la charge et libérer selon l'urgence locale.	Migrer si cela reste utile, sinon reprendre ou signaler l'arrêt.
Version incompatible	Refuser avant toute exécution.	Charger une version compatible ou choisir un autre nœud.
Tenseur incorrect	Rejeter forme, taille, position ou valeurs non valides.	Compter un défaut et retirer le nœud du plan.
Demande dupliquée	Reconnaître session, tentative et numéro d'étape.	Ne pas exécuter ni facturer deux fois une étape acceptée.
Annulation utilisateur	Arrêter l'admission, propager Cancel et clôturer.	Libérer KV et réservations ; ignorer les résultats tardifs.
Réseau coupé	Clôturer ou suspendre selon le budget de délai.	Repli local explicite si un modèle local est disponible.

Les délais d'une inférence et ceux de l'annuaire sont séparés. Un heartbeat proposé toutes les 5 secondes et une annonce expirant après 15 secondes servent à la découverte ; une requête interactive peut échouer plus vite selon son délai propre. Ces valeurs sont des paramètres initiaux à tester.

Un état simple et vérifiable

Chaque session possède un identifiant, une version de plan, un numéro de tentative et une position de token. Toute reprise augmente la tentative ou la version. Le coordinateur n'accepte que les sorties correspondant à l'état courant.

Limiter le nombre de reprises et leur coût total. Un système qui recommence indéfiniment peut consommer toutes les économies de la mutualisation. Lorsque le budget est épuisé, annoncer un échec explicite et préserver les sorties déjà validées.

Contributions, confiance et registre partagé

Un droit d’usage mesuré

La version initiale emploie des crédits internes sans valeur monétaire garantie. Une contribution rapporte des droits selon le service accepté : travail terminé, capacité réservée réellement disponible ou hébergement utile. Le prix relatif de ces services reste un paramètre à calibrer ; aucun taux universel n’est fixé ici.

Objet	Contenu minimal	Précaution
Offre	Identité, quota, types d’opérations, expiration.	Une annonce ne vaut pas preuve de capacité.
Réservation	Demande, nœud, octets et durée admis.	Révocable selon règles connues ; pas d’allocation fantôme.
Reçu	Travail, version, résultat accepté, unités et signatures.	Ne pas récompenser le simple temps pendant lequel un PC reste allumé.
Vérification	Test de conformité ou contestation documentée.	Répéter un calcul a un coût ; les contrôles partiels restent partiels.
Règlement	Lot de reçus et mise à jour des droits.	Hors du chemin interactif ; contenu privé exclu.

Version personnelle puis ouverture éventuelle

Un groupe sur invitation limite le problème des faux participants et des hôtes malveillants sans le supprimer. Pour ouvrir à tous, il faut traiter identités multiples, collusion, falsification des temps, calculs incorrects et refus de payer les contributions. Ce programme demande une validation dédiée.

La blockchain éventuelle ancre des lots de reçus. Elle ne certifie pas automatiquement qu’un nœud a possédé 7 Go libres ou qu’il a calculé correctement. Les mécanismes d’exécution vérifiable doivent être choisis et mesurés séparément. [6]

> La coopération personnelle peut être utile avant toute économie de jetons. Le registre doit améliorer le service ; il ne doit pas devenir sa raison d’être.

Modèle de données et responsabilités

Les identifiants ci-dessous sont des champs proposés pour la spécification. Les octets sont des entiers, les dates sont en UTC et chaque message porte une version de protocole. Les exemples ne désignent aucun participant réel.

Entité	Champs essentiels	Détenteur
Node	node_id, public_key, backend, device_type, status.	Annuaire du groupe.
Offer	offer_id, node_id, ram_bytes, vram_bytes, cpu_limit, expires_at.	Participant et annuaire.
Model	model_id, revision, tokenizer_hash, format, context_limit.	Catalogue.
Block	block_id, model_id, layer_start, layer_end, byte_size, digest.	Catalogue ; cache local.
Lease	lease_id, session_id, node_id, reserved_bytes, expires_at.	Participant et coordinateur.
Session	session_id, owner_key, model_revision, plan_version, token_position.	Coordinateur personnel.
Stage	session_id, attempt, stage_id, input_shape, dtype, sequence.	Exécuteurs concernés.
Receipt	receipt_id, session_id, task_digest, units, acceptance, signatures.	Participants et registre.
Metric	timestamp, memory_peak, duration, bytes_sent, energy_method.	Local puis agrégats autorisés.

Règles d’intégrité

Une version de modèle ne change pas pendant une session. Une réservation référence une offre encore valide. Une sortie doit correspondre au bloc attendu et à la version courante du plan. Un reçu a un identifiant unique : le règlement est idempotent.

Les signatures utilisent un format canonique versionné à figer dans le protocole. Les empreintes vérifient l’intégrité des blocs ; elles ne remplacent ni l’autorisation d’usage ni la preuve de calcul correct.

Contrats d’échange entre composants

Opération proposée	Entrée	Sortie attendue
Advertise	Offre signée et expiration.	Acceptée ou refus motivé.
Probe	Test autorisé et volume borné.	Débit, délai et budget observés.
Reserve / Commit	Session, blocs, contexte, quota.	Réservation puis plan confirmé.
FetchBlock	Empreinte et segment du bloc.	Octets vérifiés et reprise possible.
Prefill / Step	Session, tentative, position, tenseur.	Tenseur suivant ou token.
Cancel / Release	Session, tentative, motif.	Accusé de clôture et ressources libérées.
SubmitReceipt	Reçu signé et référence du travail.	Reçu enregistré une seule fois.

Exemple d’offre de ressources

Les valeurs suivantes illustrent un plafond de 20 % sur 16 Go décimaux. Elles n’indiquent pas qu’une telle offre a été reçue.

```
{
"protocol_version": 1,
"node_id": "exemple-noeud-01",
"ram_bytes": 3200000000,
"cpu_fraction_cap": 0.20,
"gpu_policy": "throttled_when_idle",
"trust_group": "cercle-prive",
"allowed_ops": ["prefill", "step"],
"lease_max_seconds": 60
}
```

Les tenseurs voyagent en binaire avec type, dimensions, longueur et numéro de séquence ; ils ne sont pas encodés comme une grande liste JSON. Les erreurs incluent : NO_CAPACITY, NOT_AUTHORIZED, VERSION_MISMATCH, DEADLINE_EXCEEDED, INVALID_TENSOR et CANCELLED.

Le contrat comprend également un plafond de taille de message et un plafond de demandes simultanées. La validation des dimensions doit précéder l’allocation mémoire.

Choix techniques et ordre de construction

Lot logiciel	Choix proposé	Livrable
Client et réglages	Interface locale simple ; contrôle du partage et jauges.	Autorisation, arrêt immédiat et affichage du modèle utilisé.
Gestionnaire de ressources	Service local ; limites OS lorsque disponibles.	Mesures fiables et budget couvrant tout le processus.
Moteur de modèle	Commencer par un seul modèle et un seul format.	Référence monomachine et adaptateur de blocs.
Communications	gRPC/TLS pour contrôle et prototype ; transport spécialisé possible ensuite.	Protocole versionné, bornes de flux et annulation.
Placement	Heuristique sur mémoire, temps mesuré et liaisons.	Plans reproductibles et simulation d’admission.
Persistance	Base locale pour préférences et journaux ; catalogue répliqué pour métadonnées.	Reprise sans dépendance à un serveur central unique.

Pour une première expérimentation Apple Silicon, MLX fournit des opérations de communication distribuée. [34] exo et Prima doivent être évalués comme moteurs ou références ; leur réutilisation dépend de la compatibilité du modèle et de la version retenue. [2,3]

Des exécuteurs limités à leurs opérations

Les participants ne reçoivent pas de scripts arbitraires à exécuter. Le prototype accepte des opérations prédéfinies sur des modèles autorisés, dans un processus dédié avec accès limité aux fichiers. L’isolation concrète dépend du système et de l’accès GPU ; elle doit être testée avant toute ouverture publique.

Figer les versions des moteurs, modèles et formats avant les mesures. Un changement de backend ou de quantification peut changer la qualité et les résultats numériques ; il impose une nouvelle comparaison.

Recette de l’architecture avant toute diffusion large

Test	Résultat attendu
Confort local	Le quota baisse quand l’utilisateur travaille ; la mémoire de l’exécuteur est libérée dans le délai mesuré.
Conformité des blocs	Sur entrées identiques, les sorties restent dans la tolérance numérique prévue.
Continuité	Une panne provoque reprise ou arrêt explicite, sans duplication de tokens validés.
Confidentialité	Un nœud non autorisé n’entre pas dans le plan ; aucune conversation dans le registre.
Charge et abus	Messages trop grands, offres expirées et requêtes dupliquées sont refusés.
Bilan réel	Les gains incluent réseau, veille, contrôles, répétitions et consommation du coordinateur.

La mise en service suit trois cercles : machines personnelles, participants invités, puis ouverture éventuelle après audit. Le passage de 20 à 100 participants dépend des mesures. Aucun déploiement à 1 000 personnes n’est justifié par la seule multiplication des quotas.

Le dossier est une architecture sur papier complète pour cadrer un prototype. Les schémas de messages, choix de modules et règles de reprise doivent encore devenir du logiciel, puis être confrontés au matériel. Il n’existe pas encore d’application coopérative livrée avec ce document.

Références techniques supplémentaires

[32] Linux Kernel - Control Group v2.
Documentation officielle des contrôleurs mémoire et CPU

[33] gRPC - Core concepts ; Flow control.
Concepts et cycle de vie ; contrôle de flux.

[34] MLX - Distributed Communication.
Documentation officielle du calcul distribué MLX.

Une simulation de service réellement exécutée

160 000 demandes simulées, huit scénarios, vingt répétitions.
Le programme a été exécuté. Les temps d'une IA sur du matériel réel restent des paramètres supposés : ce sont des mesures du modèle simulé, pas des benchmarks matériels.

Chaque répétition démarre avec une file vide et reçoit 1 000 demandes. Les arrivées suivent un processus de Poisson. Chaque demande contient 512 tokens d'entrée et produit 64 tokens. Une file commune affecte la prochaine demande au premier groupe libre, dans l'ordre d'arrivée.

Hypothèse	Valeur retenue
Calcul total du contexte	1,280 s, y compris la production du premier token.
Calcul par token suivant	80 ms au total, répartis entre les nœuds.
Variation du calcul	Facteur uniforme entre 0,9 et 1,1, tiré par demande.
Réseau local / Internet	1 Gbit/s, 0,5 ms par trajet / 100 Mbit/s, 20 ms par trajet.
Variation de latence	Facteur lognormal de moyenne 1 ; coefficient de variation 30 %.
Activations transmises	8 192 octets par token et frontière ; 512 fois ce volume pour le contexte.
Politique de service	Une conversation active par groupe ; pas de batch ni de chevauchement entre ses demandes.
État initial	Poids déjà chargés ; pas de temps de téléchargement à froid.

La variabilité est tirée par demande, pas paquet par paquet. La bande passante est supposée disponible ; la contention entre groupes et les limitations Wi-Fi ne sont pas modélisées. Le partage du calcul conserve le même temps total : le test isole l'effet de l'organisation et du réseau, sans supposer qu'un PC quelconque équivaut à un GPU.

Fichiers joints : service_simulation.py et service_results.json. Python standard, graines 100 à 119. Aucun résultat n'a été écarté ; les requêtes en attente sont toutes terminées après la dernière arrivée.

À quelle vitesse la file d’attente se remplit-elle ?

Même demande moyenne pour les quatre premiers scénarios : 0,1 requête/s, soit une arrivée toutes les dix secondes en moyenne. Le P95 est le délai en dessous duquel se terminent 95 % des demandes du jeu simulé. Il inclut l’attente et la réponse complète.

Configuration	Isolée[1]	Médiane	P95	Charge[2]
1 machine	6,32 s	9,35 s	26,51 s	63,2 %
4 machines locales	6,56 s	10,24 s	29,58 s	65,6 %
4 machines Internet	12,57 s	1 282,65 s	2 586,55 s	125,9 %
8 machines Internet	19,20 s	4 585,94 s	8 772,98 s	192,3 %

[1] Durée nominale d’une réponse sans attente ni variation aléatoire. [2] Charge offerte = arrivées par seconde × service moyen ÷ nombre de groupes. Au-delà de 100 %, la file ne possède pas de régime stationnaire dans ce modèle.

Les grands délais Internet signalent une surcharge, pas une latence réseau de plusieurs minutes. Les requêtes arrivent plus vite que le groupe ne les termine. Les P95 de ces lignes dépendent donc de la durée de l’expérience ; ils ne prédisent pas un service stable.

Si l’on réduit la demande Internet à 0,04 requête/s

Configuration	Charge	Médiane	P95
4 machines Internet	50,4 %	14,75 s	39,81 s
8 machines Internet	76,9 %	39,43 s	132,48 s

Une arrivée toutes les 25 secondes en moyenne rend ces deux files stables sous les hypothèses choisies. Cela ne supprime pas les pointes d’attente. Le délai du premier token et celui de la réponse complète sont fournis séparément dans le JSON.

Le premier token est produit par le traitement du contexte, puis 63 étapes génèrent les tokens restants. Cela explique la différence entre le temps total par réponse ici et une multiplication simple des tokens/s de la page 6.

L’intérêt du collectif : plusieurs groupes en parallèle

Le scénario suivant utilise **huit groupes de quatre machines, soit 32 machines actives**, avec une file commune. Il reçoit 0,8 requête/s au total, huit fois la demande du groupe local précédent. Chaque groupe garde la même vitesse nominale pour une demande isolée.

Scénario	Médiane	P95	1er token P95	Tokens/s[3]
1 groupe local, 0,1 req/s	10,24	29,58	24,41	6,38
8 groupes, 0,8 req/s	6,68	8,62	3,41	50,84
8 groupes avec incidents	6,70	9,15	3,63	50,82

Délais en secondes. [3] Débit collectif observé dans la simulation, temps de vidage final inclus. Ce débit dépend de la charge injectée : il ne représente pas la capacité maximale du système.

Résultat du scénario : à charge proportionnelle, la file commune répartit les pointes entre les groupes. Le P95 passe de 29,58 s pour un groupe à 8,62 s pour huit groupes. Ce gain de mutualisation n’accélère pas le calcul individuel et utilise huit fois plus de groupes.

Incidents : une hypothèse injectée, pas un taux observé

Pour chaque nœud actif, la simulation suppose un temps moyen de 1 800 secondes de calcul avant incident, avec événements indépendants. Elle ajoute 2 secondes de détection, 3 secondes de bascule vers une copie déjà chargée, puis un coût de reconstruction du contexte. Les incidents pendant cette reconstruction et les pannes communes sont exclus.

Sur 20 000 demandes de ce scénario, 264 ont subi au moins un incident, pour 268 événements. Le P95 obtenu est 9,15 s. Les copies de secours ont un coût mémoire et matériel supplémentaire ; leur disponibilité est supposée ici, pas démontrée.

Le résultat ne constitue pas une preuve de résilience. Il chiffre un mécanisme de reprise sous des hypothèses explicites ; un essai réel doit inclure déconnexions simultanées, capacité de secours limitée et reprise des caches.

Comment utiliser ces résultats sur le site et dans le prototype

Ce qu’on peut publier dès maintenant

Une rubrique « Performances simulées » peut afficher ces huit scénarios, les paramètres, les médianes et les P95. Les valeurs de référence doivent rester attachées à leur scénario. Modifier le curseur de RAM ne permet pas de recalculer arbitrairement une vitesse de calcul.

Dans le site	Présentation correcte
Mémoire	Formules dynamiques en fonction des quotas, de la disponibilité et des copies.
Réseau	Estimation analytique modifiable avec le délai et le débit.
File de demandes	Jeu de résultats de référence issu de cette exécution, ou nouvelle simulation avec ses paramètres et sa graine affichés.
Chaleur / énergie	Bilan conditionnel ; pas de gain énergétique global déduit des seuls temps simulés.
Prototype réel	Résultats futurs séparés, avec modèle, matériel, moteur, version et protocole de mesure.

Les incertitudes qui comptent

Les temps de calcul supposés doivent être remplacés par des mesures. Ce simulateur ne charge aucun modèle : il n’en vérifie ni la qualité, ni les sorties, ni les limites mémoire réelles. Il exclut le batching, le pipeline de plusieurs conversations dans un groupe, le chargement à froid et les échanges concurrents sur une même liaison. Ces choix peuvent fortement changer les conclusions chiffrées.

Les vingt répétitions révèlent la variation due aux tirages ; elles ne couvrent pas l’incertitude des hypothèses. Pour huit groupes locaux, le P95 par répétition varie de 7,83 à 9,42 s. Ce n’est pas un intervalle de confiance sur une future application.

La prochaine mesure utile

Mesurer le traitement de 512 tokens et la production de 64 tokens avec un modèle identifié, d’abord sur une machine, puis sur deux à quatre machines. Injecter ces temps, les pics mémoire et les liaisons mesurées dans le simulateur. Vérifier ensuite ses prédictions sur des demandes concurrentes.

Contact et attribution
Concept et orientation : Renaud Ben Lakhal.
contact@renaud.brussels
Recherche, formalisation et simulations avec assistance IA.

Le logiciel expliqué sans vocabulaire technique

L’idée en une phrase : installer un programme qui permet à son ordinateur d’aider un cercle de participants, dans la limite choisie, tout en restant disponible pour son propriétaire.

Le cercle rassemble des appareils autorisés. Une demande utilise seulement les machines qui conviennent à son modèle et à son délai. La mémoire reste sur chaque ordinateur ; celui-ci effectue une partie du travail avant de transmettre ce dont le suivant a besoin.

Mot technique	Explication pour l’utilisateur
Nœud	Un ordinateur qui participe.
Quota	La limite de ressources que vous acceptez de prêter.
Bloc du modèle	Une partie du programme de calcul et de ses paramètres.
Cache de conversation	La mémoire temporaire nécessaire pour poursuivre la réponse.
Maillage	Plusieurs connexions possibles entre les ordinateurs.
Relais	Un intermédiaire qui aide deux machines à communiquer.

Le parcours à rendre simple

1. Installer et ouvrir l’application.
2. Créer un cercle ou ouvrir une invitation.
3. Choisir sa contribution et les horaires autorisés.
4. Laisser l’application vérifier le modèle et les connexions.
5. Utiliser le service, avec un bouton d’arrêt toujours visible.

Ce parcours décrit la future application. Le dépôt actuel fournit les calculs, les simulations et des outils de recherche ; il ne crée pas encore un cercle opérationnel.

Installer simplement, sans masquer ce qui se passe

La cible est une application signée sur Mac, puis des paquets adaptés à Windows et Linux. L'utilisateur ne devrait pas devoir installer séparément une chaîne de bibliothèques, configurer des ports ou saisir des commandes pour rejoindre un cercle. Ce travail d'intégration reste à réaliser.

Écran	Ce que l'utilisateur doit comprendre
Bienvenue	Ce que le programme fait ; ce qui sera partagé ; où se trouvent les réglages.
Mon cercle	Créer un cercle personnel ou rejoindre une invitation dont le créateur est identifiable.
Ma contribution	Plafond choisi, réserve pour le travail personnel, secteur/batterie et arrêt immédiat.
Modèle	Nom et version ; volume à télécharger ; espace et mémoire nécessaires ; consentement avant téléchargement.
Vérification	Test court du moteur, du budget et de la liaison ; problème expliqué avec une action possible.
Prêt	Modèle réellement utilisé, machines impliquées et état de la contribution.

Exemple : avec 36 Go, 20 % représente un plafond de 7,2 Go. Le programme peut prêter moins si le travail personnel exige davantage de mémoire. Le chiffre ne doit pas être présenté comme une allocation permanente.

La mise à jour doit vérifier l'origine des composants et préserver les préférences. La désinstallation sépare application, modèles téléchargés et éventuelles données locales ; elle ne supprime pas les documents personnels. L'application ne doit pas demander de désactiver les protections du système pour fonctionner.

Un site Base44 de présentation peut expliquer et simuler ce parcours. Il ne peut pas, par sa seule présence dans un navigateur, transformer les ordinateurs des visiteurs en un réseau de calcul géré par notre application.

Le maillage : se trouver, se relier, coopérer

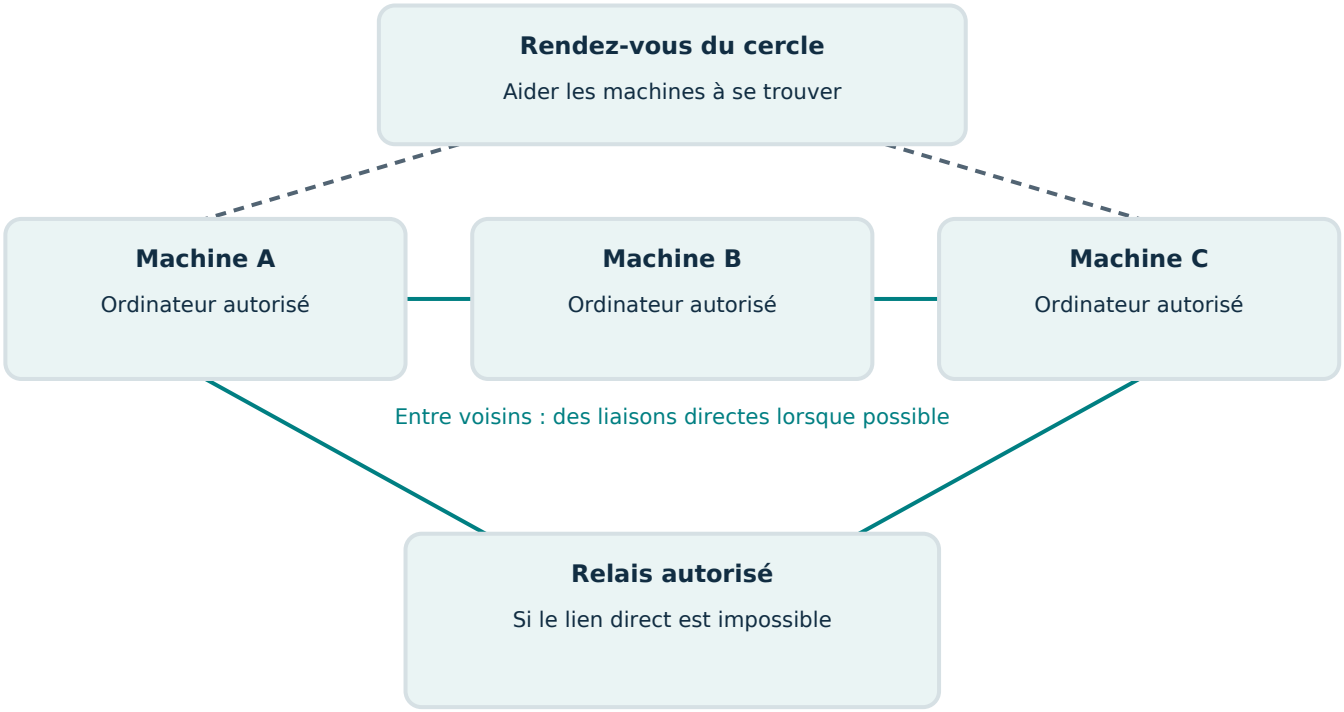


Schéma conceptuel, pas carte d'un réseau existant. Les pointillés représentent la découverte. Les autres traits représentent des liaisons entre pairs ou via un relais. Le travail IA ne doit pas passer systématiquement par le rendez-vous.

Le maillage comporte plusieurs chemins possibles ; il ne relie pas nécessairement chaque ordinateur à tous les autres. Mille machines entièrement reliées deux à deux représenteraient 499 500 liaisons. Le protocole doit limiter les voisins et les messages de présence tout en préservant une connectivité testée.

Couche	Fonction
Découverte et contrôle	Trouver les voisins, vérifier les autorisations, annoncer les ressources et réserver.
Calcul	Relier le petit ensemble de participants retenus pour une demande.
Comptabilité	Échanger les reçus après le travail ; aucune blockchain nécessaire au premier cercle.

Un réseau maillé ne rend pas Internet aussi rapide qu'un bus mémoire. Deux chemins peuvent être disponibles mais trop lents pour la génération interactive. Le contrôleur peut alors proposer une tâche autonome ou refuser le placement.

Créer ou rejoindre un cercle : le déroulement concret

Créer

Le propriétaire nomme le cercle et crée son identité locale. L'invitation décrit le cercle, son autorité, les points de rendez-vous et un jeton à durée limitée. Elle ne contient aucune clé privée. Le premier pilote peut accepter un rendez-vous unique, à condition d'afficher cette dépendance ; la redondance vient avant toute promesse de disponibilité indépendante.

Rejoindre

1. Ouvrir l'invitation et vérifier le cercle annoncé.
2. Valider l'entrée de l'appareil et échanger les clés publiques.
3. Annoncer moteurs, formats, ressources et types de tâches acceptés.
4. Réaliser un petit test sans données privées.
5. Afficher les connexions et le quota réellement admis.

Trouver une liaison

Sur un réseau local, une découverte de type mDNS peut signaler les appareils ; elle ne les autorise pas à travailler. À distance, un rendez-vous aide les machines à se rencontrer. Une liaison directe est préférée ; si les routeurs l'empêchent, un relais autorisé peut transporter le canal chiffré. Les mécanismes STUN et TURN documentent ces besoins de traversée NAT et de relais. [35-37]

Pour le premier pilote, un réseau privé existant simplifie l'adressage. Tailscale ou une infrastructure Headscale administrée sont des options à évaluer. Ils ont leur propre configuration ; ils ne remplacent ni l'authentification du programme, ni la confiance dans l'ordinateur qui calcule. [38]

Ce que l'interface doit dire : « Connexion directe », « Connexion par relais », « Autorisation manquante » ou « Liaison trop lente pour cette tâche ». Un bouton vert ne suffit pas à expliquer le service disponible.

Ces fonctions de découverte et d'invitation sont spécifiées ici, mais ne sont pas encore implémentées dans le socle logiciel publié.

Un réseau fonctionnel doit aussi expliquer ses échecs

Situation	Message et comportement attendus
Le propriétaire reprend son travail	« Contribution réduite pour garder votre ordinateur disponible. » Suspendre les tâches différables.
Une machine quitte le cercle	« Un participant s’est déconnecté. » Reprendre avec un remplaçant compatible, reconstruire l’état, ou signaler un arrêt.
L’invitation est expirée	« Demandez une nouvelle invitation. » Ne pas accepter une ancienne autorisation indéfiniment.
Le réseau utilise un relais	Indiquer le chemin indirect et mesurer son coût ; ne pas masquer une dégradation.
Le modèle ne tient pas	Expliquer les ressources manquantes ; proposer un autre modèle en le nommant.
L’utilisateur arrête le partage	Refuser les nouveaux travaux, annuler ou clôturer proprement, libérer les ressources.

Ce que l’ingénierie doit garantir avant un pilote

Les annonces expirent ; les clés et autorisations sont vérifiées ; les révocations sont propagées et versionnées. Le nombre de voisins, les battements de présence et les délais sont mesurés en conditions réelles. Les coupures communes et les partitions du réseau font partie des essais.

Plusieurs chemins ne remplacent pas une copie des poids, et une copie des poids ne remplace pas le cache de conversation. La continuité doit être testée sur une réponse réelle. Le propriétaire d’un ordinateur qui calcule peut accéder à certaines données traitées : l’interface doit rendre le niveau de confiance compréhensible.

Objectif de simplicité : faire rejoindre un cercle test par une personne sans expérience réseau, puis lui faire réduire et arrêter sa contribution sans Terminal. Objectif à valider, pas résultat déjà obtenu.

Les premiers pas disponibles et la suite à construire

Le dépôt public github.com/renaud-bxl/ia-cooperative rassemble le catalogue logiciel, le socle Python, le carnet de réflexion et les simulations. Attribution : Renaud Ben Lakhal ; contact@renaud.brussels.

Essayer le socle aujourd’hui

Télécharger le ZIP depuis GitHub, le décompresser, puis utiliser Python 3.11 ou plus récent. Le fichier Demarrer.command lance une démonstration hors ligne sur Mac. Si Python manque, utiliser son installateur officiel. Aucun modèle ni réseau n’est installé par ce lanceur.

```
python3 -m coopai quota --installed-gb 36
--available-gb 12 --reserve-gb 2 --percent 20

python3 -m coopai plan examples/mac_circle.json
```

La première commande, à saisir sur une seule ligne, calcule un plafond de 7,2 Go. La seconde estime un placement sur un parc fictif. Le client de benchmark fourni peut ensuite mesurer un modèle Ollama déjà installé ; il n’a pas été exécuté sur les machines de l’utilisateur.

Déjà livré	À développer et valider
Dossier, schémas et catalogue de logiciels.	Application graphique et installateurs signés.
Quotas et placement théorique testables.	Contrôle réel des ressources et intégration d’un moteur.
Simulations et client de mesure locale.	Invitations, maillage, relais et inférence multi-machine.

Références de cette extension

[35] mDNS : RFC 6762. **[36]** STUN : RFC 8489. **[37]** TURN : RFC 8656.

[38] Documentation Tailscale et dépôt officiel Headscale. **[39]** Installation : Python officiel ; mesures : API Ollama.

De machine en machine : quelle infrastructure faut-il ?

Le calcul peut être directement réparti entre les participants.
L'application graphique s'installe sur leur ordinateur. Un serveur central hébergeant toute l'IA n'est pas une obligation de cette architecture.

Situation	Infrastructure nécessaire
Sur le même réseau local	Les ordinateurs, leur connexion et les composants déjà téléchargés. Aucun service extérieur indispensable pendant le calcul.
Entre plusieurs logements	Adresses connues ou rendez-vous pour se trouver ; liaison directe si possible ; relais dans certains réseaux.
Réseau mondial simple à rejoindre	Plusieurs rendez-vous accessibles, capacité de relais, distribution de versions et supervision. Calcul organisé par groupes adaptés.

Trois rôles différents

Le **participant** exécute le calcul. Le **rendez-vous** aide les machines à se trouver, comme un carnet d'adresses. Le **relais** transporte les échanges quand la connexion directe est impossible. Ces services auxiliaires ne doivent pas nécessairement posséder tout le modèle.

Des machines de participants peuvent assurer rendez-vous et relais, si elles sont accessibles et assez disponibles. Un petit serveur administré est une option pratique pour une adresse stable. Si tous les participants sont derrière des routeurs qui empêchent le contact direct, un intermédiaire accessible devient nécessaire ; aucune promesse de connexion universelle ne peut ignorer ce cas.

La première version à tester

Deux à quatre ordinateurs sur le même réseau, sans cloud de calcul. Puis deux ou trois adresses différentes pour mesurer débit montant, routeurs, connexions directes, relais et reprises. La distance géographique ne suffit pas à prédire la qualité du lien.

Le premier téléchargement des logiciels et modèles reste nécessaire. Une fois les fichiers présents, un essai local peut fonctionner sans Internet. Le propriétaire garde localement ses clés et ses réglages ; le coordinateur peut se trouver sur la machine qui initie la demande.

Un rendez-vous mondial pour tester ensemble

L’objectif est une bêta internationale à une heure commune, après les essais privés. Aucun calendrier n’est annoncé ici. Le lancement est conditionné à des démonstrations réelles et à une répétition générale.

Étape	Validation attendue
1. Local : 2 à 3 machines	Installation, calcul partagé réel, modèle identique, quotas et arrêt.
2. Deux ou trois adresses	Opérateurs différents si possible ; NAT, relais, débit montant, reprise et confiance.
3. Bêta invitée	Plusieurs régions, matériel varié et installation par des personnes non techniques.
4. Répétition générale	Version commune, modèles préchargés, bascule des services et procédure d’annulation.
5. Test mondial	Entrée par vagues à l’heure UTC annoncée ; mesures et bilan public.

Tous ensemble ne signifie pas tous dans la même chaîne de calcul. Les machines forment des groupes selon leurs connexions et permissions. Le réseau mondial traite plusieurs tâches en parallèle ; une réponse n’a pas besoin de traverser tous les continents à chaque mot.

Les logiciels et modèles sont téléchargés avant l’heure H. À H, les participants activent leur disponibilité. Le site convertit l’heure UTC dans leur fuseau, affiche les prérequis et, quand le service existe réellement, les mesures agrégées et les incidents.

Ce qui autorise l’annonce d’une date

Installateur vérifié, essais locaux et entre adresses concluants selon des critères fixés, capacité de secours connue, limites d’admission, assistance et arrêt d’urgence. Le premier rendez-vous public demeure un test expérimental, pas une garantie de service permanent.

Le bilan distingue inscriptions et participants actifs, mémoire annoncée et utilisée, tâches terminées, qualité, P95, relais, pannes et coûts auxiliaires. Les métriques inconnues restent inconnues. Les tests utilisent des données publiques ou synthétiques.

Plan détaillé : docs/GLOBAL_TEST.md. Contact : contact@renaud.brussels.